

PROJET DATA ANALYST

Analyse de comportement de Clients

Par SOW Thierno Djiby

I)Présentation du Projet :

Dans ce projet , nous analysons le comportement d'achat des clients d'une boutique à partir d'une base de données de 3900 achats de plusieurs catégories de produits . Notre but est de faire une analyse approfondie de ces données afin de guider les décisions stratégiques du propriétaire de cette boutique .

II)Présentation du Dataset :

- Nombre de lignes : 3900
- Nombre de colonnes : 18
- Caractéristiques:
 - Informations biographiques des clients : Âge , Genre , Adresse , Abonnement
 - Informations d'achat: Objets achetés , Catégories , Montant , saison , Taille , couleur
 - Information sur la Boutique: Code de promo , Achats précédents , Fréquences d'achat , taux de satisfaction , types de vente
 - Valeurs manquantes : 37 valeurs sur la colonne taux de satisfaction

III)Analyse Exploratoire des données avec Python:

J'ai commencé par un nettoyage des données sur python :

- **Chargement des données** : chargement des données avec **pandas**
- **Exploration initiale** : j'utilise la commande `df.info()` pour voir la structure de la base de données et `df.describe()` pour avoir un aperçu des stats descriptives .

	customer_id	age	purchase_amount	review_rating	previous_purchases
count	3900.000000	3900.000000	3900.000000	3900.000000	3900.000000
mean	1950.500000	44.068462	59.764359	3.750051	25.351538
std	1125.977353	15.207589	23.685392	0.713590	14.447125
min	1.000000	18.000000	20.000000	2.500000	1.000000
25%	975.750000	31.000000	39.000000	3.100000	13.000000
50%	1950.500000	44.000000	60.000000	3.800000	25.000000
75%	2925.250000	57.000000	81.000000	4.400000	38.000000
max	3900.000000	70.000000	100.000000	5.000000	50.000000

- **Valeurs manquantes** : Dans la colonne des taux de satisfaction , j'ai remplacé chaque valeur manquante par la médiane de la catégorie de produit concernée . Cela nous évite de prendre la moyenne globale qui a plus de risque de fausser nos analyses .
- **Standardisation des colonnes** : J'ai renommé les colonnes (accolées , séparées par des tirets du bas) pour avoir une meilleure documentation en vue des requêtes sql .
- **Consistance des colonnes** : J'ai supprimé la colonne **discount_applied** qui est redondante au vu de la colonne **promo_code_used** .
- **Feature Engineering** :
 - ❖ Création de la colonne **Age_group** pour mieux catégoriser les clients
 - ❖ Création de la colonne **purchase_frequency_days** pour chiffrer la fréquence d'achat

Une fois cette étape d'Analyse exploratoire terminée , j'ai enregistré la base de données finale en **customer.csv** en vue de l'analyse sur SQL .

IV)Analyse de données sur SQL avec Databricks :

J'ai procédé par la suite par une analyse de données pour répondre à certaines questions de business stratégiques :

- 1) **Revenu par genre** : Comparaison des revenus générés à partir des clients hommes et des clients femmes

	^A _C gender	¹ ₂ revenue
1	Male	157890
2	Female	75191

- 2) **Clients les plus acheteurs** : Identifier les clients qui achètent le plus en terme de montant à la boutique .

	¹ ₂ customer_id	¹ ₂ purchase_amount
1	2	64
2	3	73
3	4	90
4	7	85
5	9	97
6	12	68
7	13	72
8	16	81
9	20	90

- 3) **Top 5 des produits les mieux notés** : Identifier les produits les plus appréciés par les clients

	A^B_C item_purchased	1.2 review_rating_mean
1	Gloves	3.8614285714285725
2	Sandals	3.8443750000000003
3	Boots	3.8187500000000005
4	Hat	3.8012987012987005
5	Skirt	3.784810126582278

- 4) **Express vs Standard** : Comparer les ventes Standards et les ventes Express

	A^B_C shipping_type	1.2 avg_purchase_amount
1	Express	60.475
2	Standard	58.46

- 5) **Abonnés versus Non Abonnés** : Comparer les dépenses des abonnées et des non abonnées . Cela permet d'avoir une idée du retour des abonnés par rapport aux non abonnés .

	A^B_C subscription_status	1.2 avg_purchase_amount	1^2_3 total_customers	1^2_3 total_revenue
1	Yes	59.49192782526116	1053	62645
2	No	59.865121180189675	2847	170436

- 6) **Top 5 produits avec promotion** : Savoir les 5 produits les plus vendus avec des promotions .

	A_C^B item_purchased	1.2 discounted_rate
1	Hat	50
2	Sneakers	49.6551724137931
3	Coat	49.06832298136646
4	Sweater	48.170731707317074
5	Pants	47.368421052631575

- 7) **Segmentation des clients** : Catégorisation des clients en nouveaux , les habitués et loyaux .

	A_C^B customer_segment	1_3^2 total_count
1	Loyal	3116
2	Returning	701
3	New	83

- 8) **Top 3 des produits** les plus **achetés** dans chaque catégorie .

	A_C^B item_purchased	1_3^2 total_product	A_C^B category
1	Jewelry	171	Accessories
2	Sunglasses	161	Accessories
3	Belt	161	Accessories
4	Blouse	171	Clothing
5	Pants	171	Clothing
6	Shirt	169	Clothing
7	Sandals	160	Footwear
8	Shoes	150	Footwear
9	Sneakers	145	Footwear
10	Jacket	163	Outerwear


- 9) **Clients** : Nombre de clients abonnées parmi ceux qui achètent le plus à la boutique . Cette statistique nous permet de voir notre capacité à augmenter notre nombre d'abonnés .

	A_C^B subscription_status	1_3^2 repeat_buyers
1	Yes	958
2	No	2518

10) **Groupes d'âge** : Le revenu généré à partir de chaque catégorie d'âge . A partir de là , le propriétaire sera sa base clientèle (jeunes , adultes , seniors etc.....) .

	^A _C age_groupe	¹ ₂ total_revenue
1	senior	93410
2	Middle Aged	65013
3	Adult	45400
4	Young Adult	29258

V)Dashboard sur Power BI :



VI)Recommendations Business :

1. **Augmenter les abonnés** : Mettre en place par exemple des promotions spécifiques pour les abonnés pour inciter les clients à s'abonner et donc à se fidéliser davantage .
2. **Programme de fidélité** : Récompenser les clients les plus fidèles .

3. **Promotion** : Améliorer les politiques de promotion
4. **Asseoir la base** : Les seniors sont ceux qui achètent le plus dans la boutique donc ce serait intéressant d'essayer de les fidéliser .
5. **Ciblage** : Faire un marketing concentré sur les clients aux hauts revenus (dans notre analyse , la moyenne est relativement modeste .) Inciter par exemple , les jeunes à acheter via des programmes par l'introduction de nouveaux produits pouvant les intéresser .